#### Тема лекції 12:

Оптимізація запитів до бази даних

- □ Використання індексів в системах з базами даних
- Рекомендації з використання індексів в SQL Server
- □ Використання кластерних індексів
- □ Використання некластерних індексів
- Рекомендації щодо написання запитів на вибірку даних

### Використання індексів в системах з базами даних

- З погляду користувача, індекс це перелік стовпців таблиці, за значеннями яких записи логічно впорядковуються.
- □ З погляду СУБД, індекс це механізм, що дає змогу значно підвищити швидкість доступу до записів за індексованими полями та забезпечує ефективну перевірку унікальності значень індексованих полів.

#### Індекси забезпечують:

- задоволення вимоги унікальності записів
- □ підтримку логічної, а у випадку кластеризованих таблиць і фізичної, упорядкованості даних відповідно до значень одного чи декількох полів
- оптимізацію виконання запитів

#### Правила використання індексів

- у таблицях невеликих розмірів індекси майже не забезпечують підвищення продуктивності
- продуктивність значно підвищується в тих випадках, коли стовпці містять переважно неповторювані дані
- □ завдяки індексам оптимізується виконання запитів, які видають достатньо велику кількість результатних рядків (від 25% і більше)
- □ слід пам'ятати, що індекси прискорюють пошук даних, однак сповільнюють процес їхнього оновлення, що стає особливо відчутним під час одночасного оновлення великої кількості рядків. (У подібних випадках перед оновленням індекс потрібно видаляти, а після завершення даної операції відновити)

#### Правила використання індексів

- зберігання індексів потребує значних обсягів пам'яті. Якщо СУБД дає змогу керувати пам'яттю, слід відвести частину пам'яті під індекси;
- потрібно завжди індексувати поля, що використовуються для з'єднання таблиць – це значно прискорює виконання запитів;
- не слід індексувати поля, які регулярно оновлюються;
- не бажано зберігати індекси разом з таблицями на одному фізичному пристрої. Розподіл цих об'єктів між носіями інформації знижує навантаження на них та прискорює виконання запитів.

#### Прості та складені індекси

- □ Індекси можуть бути побудовані на декількох полях.
- □ Якщо для одного індексу вказується більш ніж одне поле, то друге поле впорядковується всередині першого, третє всередині другого і т.д. Це виконується незалежно від способу впорядкування стовпців у таблиці.
- У складених індексах слід спочатку зазначати поля, що використовуються найчастіше.
- Складені індекси потрібно застосовувати тоді, коли зазначені в них поля використовуються для опису умови вибору даних.

### Рекомендації з використання індексів в SQL Server

- □ Основним засобом підвищення швидкості виконання запитів на вибірку даних є створення необхідних індексів.
- □ Перед тим як створювати оптимальні індекси для таблиць необхідно передбачити, які запити і в які моменти часу будуть виконуватись в базі даних, що є непростою задачею, особливо, якщо робляться спроби додати індекси до нової бази даних.
- □ Оптимізуючи індекси для бази даних, насамперед необхідно *ідентифікувати проблемні запити*. Це запити, які найчастіше виконуються, а також такі, які є найбільш трудоємними з точки зору затрат ресурсів, які виконуються у моменти загального навантаження на сервер.

# Типи індексів для оптимізації виконання запитів

- □ кластерний або некластерний
- унікальний або неунікальний
- □ простий чи складений
- повнотабличні або фільтровані некластерні індекси

### Параметри індексів для оптимізації виконання запитів

- Можна задати початкові характеристики сховища індексу, щоб оптимізувати його продуктивність або підтримку, задавши такий його параметр як FILLFACTOR.
- Додатково можна визначити місце зберігання індексу за допомогою файлових груп або схем секціонування.

#### Використання кластерних індексів

- Кластерний індекс відповідає фізичному порядку сортування даних в таблиці. Звідси випливає, що таблиця може мати лише один кластерний індекс.
- Як правило, цей кластерний індекс використовують для реалізації обмеження первинного ключа. Тому кластерний індекс володіє обмеженням унікальності.
- □ Умова унікальності не є обов'язковою. Однак, неунікальний кластерний індекс автоматично включає в себе додаткову інформацію, розміром 4байта на кожен індексний запис для того, щоб гарантувати їх унікальність на скритому від користувача рівні. Це призводить до збільшення розміру кластерного індексу.

### Правило 1 кластеризації таблиць

- □ Кожна таблиця повинна мати кластерний індекс
- □ Пояснення цьому правилу пов'язане з особливістю SQL Server зчитувати дані.
  - Коли зчитуються дані, які зберігаються в кластерному індексі, SQL Server має можливість за одну елементарну операцію читати цілий екстент (8 послідовних сторінок або 64 Кбайта).
  - Для порівняння некластерні індекси і дані з таблиць зчитуються посторінково (8 Кбайт за одну елементарну операцію читання). Тому перевага від наявності кластерних індексі є очевидною.
- □ Наявність кластерного індексу в таблиці гарантує, що сторінки даних цієї таблиці будуть дефрагментовані при операції перебудови індексів.

### Правило 2 кластеризації таблиць

- □ Кластерний індекс треба створювати перед створенням будь-яких некластерних індексів.
  - Якщо такий порядок порушити, то при створенні кластерного індексу усі некластерні індекси будуть перебудовані автоматично, що є довготривалим процесом.

### Правило 3 кластеризації таблиць

- Якщо таблиця має і кластерний і некластерні індекси, то рекомендується, щоб кластерний індекс базувався на єдиному стовпці мінімальної довжини.
- Часто цю умову задовольняє атомарний автоінкрементний первинний ключ таблиці.
  - У цьому випадку є ще одна перевага, а саме, виключається розщеплення сторінок даних. Тобто якщо в таблицю з автоінкрементним кластерним індексом вставляються нові рядки, то ці вставки фізично реалізуються послідовно одна за другою, і не буде відбуватись розбиття сторінок.
- У загальному випадку необхідно так визначити кластерний індекс, щоб в нього увійшло якомога менше стовпців.

### Правило 4 кластеризації таблиць

- □ Неефективним є вибір широких атрибутів для кластерних індексів.
  - Ключові значення з кластерного індексу використовуються всіма некластерними індексами як уточнюючі. Тому будь-які некластерні індекси, визначені на тій же таблиці, будуть значно більшими.

### Атрибути – претенденти на кластерний індекс

- унікальні атрибути або ті, які містять багато різних значень
- звернення до цих атрибутів відбувається послідовно
- атрибути, які часто використовуються для сортування даних

## Випадки застосування кластерних індексів

- □ Запити повертають діапазон значень за допомогою предикатів BETWEEN, >, >=, < і <=.</li>
  - У таких випадках після того як знайдено перший рядок за допомогою кластерного індексу, рядки з наступними індексованими значеннями гарантовано будуть фізично суміжними зі знайденим рядком.
- Запити повертають великі результатні набори (до 75%).
- □ Запити містять операцію з'єднання таблиць (JOIN);
  - як правило, в них беруть участь і стовпці зовнішнього ключа.

## Випадки застосування кластерних індексів

- □ Запити використовують фрази GROUP BY або ORDER BY.
  - У цих випадках індекс за стовпцями, вказаними в таких фразах, виключає потребу у сортуванні даних, оскільки рядки вже посортовані. Це й покращує продуктивність запиту.
- □ Запити з групуванням і агрегатними функціями, такими як МАХ, МІN або COUNT, оскільки усі ці операції виконуються через проміжну операцію сортування даних.

### Використання некластерних індексів

- □ Некластерні індекси створюють для підвищення ефективності запитів, які часто використовуються і не враховуються кластерними індексами.
- □ При проектуванні некластерних індексів необхідно враховувати характеристики систем з базами даних.

### Використання некластерних індексів в OLAP-системах

- Запити до бази даних можуть виконуватись швидше при використанні великої кількості некластерних індексів.
- У процесі визначення найшвидшого методу доступу оптимізатор запитів може вибирати з великої кількості індексів.
- Якщо база даних не призначена для частих оновлень, то операції з обслуговування індексів не будуть впливати на швидкодію системи.

### Використання некластерних індексів в OLTP-системах

- Необхідно уникати великої кількості некластерних індексів.
- Крім того, індекси повинні бути вузькими, тобто містити мінімальну кількість стовпців.
- □ Велика кількість індексів в таблиці знижує швидкість виконання операцій INSERT, UPDATE та DELETE, оскільки при зміні даних усі індекси повинні перебудуватись.

#### Поняття селективності стовпця

- $\square$  Селективність стовпця Sназивається відношення кардинальності вибірки за цим стовпцем, k, до кардинальності  $\mathcal{L} = \frac{100\%}{100\%}$  цілої таблиці, C, яке виражається у  $\mathcal{L} = \frac{100\%}{100\%}$  процентах: процентах:
  - $\blacksquare$  де k кількість різних значень в стовпці, а C – кількість рядків в таблиці.
- Параметри k та C завжди включаються в статистику таблиці, тому оптимізатор може оперувати ними при побудові плану запиту.

$$S = \frac{k}{C}100\%$$

## Випадки застосування некластерних індексів

- Запит повертає невелику кількість рядків (через фільтрування) і індексований стовпець має хорошу селективність (більше 95%).
  - Якщо селективність менша 95%, то скоріш за все оптимізатор не буде використовувати для виконання операції пошуку некластерний індекс, який базується на цьому стовпці.
  - Змінити поріг селективності не можна, але можна явно через підказку наказати оптимізатору використати індекс.

# Випадки застосування некластерних індексів

- Фрази WHERE та ORDER BY визначені для одного і того ж стовпця.
  - У цьому випадку некластерний індекс має подвійну перевагу: прискорює пошук потрібних записів і їх сортування, оскільки вибрані дані вже посортовані.
  - Зауважимо, що для великої кількості результатних рядків більш корисними є кластерні індекси.

## Випадки застосування некластерних індексів

- □ При використанні операції з'єднання таблиць (JOIN) та групування (GROUP BY).
  - Необхідно створити некластерні індекси для стовпців, які беруть участь в операціях з'єднання і групування
- Стовпець або стовпці, які будуть проіндексовані, є широкими.
  - Хоча створення індексів на широкі стовпці є в принципі неефективним способом, то у випадках, коли немає інших варіантів оптимізації, використовують некластерні індекси.

### Робота з некластерними індексами

- Навіть коли стовпець має некластерний індекс, оптимізатор не завжди використовує його в операції пошуку.
  - Замість цього виконує сканування таблиці або кластерного індексу, що знижує ефективність виконання запиту.
  - Така ситуація виникає при кореляції (прямому зв'язку) даних
- □ Наприклад, некластерний індекс створено для стовпця, що містить дату операції, а кластерний для стовпця з номером операції. У цьому випадку є кореляція між датами, які зростають, і відповідними номерами замовлень, які зростають. Оптимізатор працює у припущенні, що немає кореляції. І це веде до помилкових рішень.

### Способи керування оптимізацією

- необхідно перевпорядкувати
  складений некластерний індекс так,
  щоб на першому місці був найбільш
  селективний стовпець
- □ створити покриваючий індекс
- □ дати підказку оптимізатору

# Покриваючі індекси (Covering Indexes)

- □ Некластерні складені індекси корисні тоді, коли вони є покриваючими індексами.
- □ Продуктивність підвищується у тих випадках, коли індекс містить усі стовпці запиту.
  - У цьому випадку оптимізатор може знайти усі значення стовпців всередині цього індексу.
  - Тоді відпадає необхідність звертатись до таблиць або даних кластерних індексів, в результаті чого знижується інтенсивність дискових операцій введення / виведення.
  - Для розширення покриття стовпців не потрібно створювати широкий ключ індекса, а треба використовувати індекс з включеними стовпцями.

### Побудова покриваючого індексу

- □ Треба включити в некластерний індекс усі стовпці, які зустрічаються у фразах SELECT, JOIN і WHERE.
- □ Корисними можуть бути такі індекси і в операціях групування GROUP BY.
- □ Якщо таблиця має кластерний індекс, то стовпець (або стовпці) кластерного індексу автоматично додається вкінець кожного некластерного індексу таблиці. Це може призвести до виникнення покриваючого індексу без вказання стовпця кластерного індексу у визначенні некластерного індексу.

### Відфільтровані індекси

- Відфільтрований індекс це оптимізований некластерний індекс, який підходить для запитів, які виконують вибірку з наперед визначеного набору даних.
- Він використовує предикат фільтрації для індексування частини рядків в таблиці.
- У створенні такого індексу використовується фраза WHERE.
- Добре спроектований відфільтрований індекс дозволяє оптимізувати запити, знизити затрати на обслуговування та зберігання індексів у порівнянні з повнотабличними некластерними індексами.

## Випадки застосування відфільтрованих індексів

- □ Якщо у стовпця є мало унікальних значень, наприклад лише 0 і 1, то при виконанні більшості запитів некластерний індекс, побудований на цьому стовпці, не буде використовуватись.
- □ Для такого типу даних можна створити відфільтрований індекс для окремого значення, яке з'являється в невеликій кількості рядків.
  - Наприклад, якщо більшість значень рівне 0, то оптимізатор може використати відфільтрований індекс для рядків даних, в яких міститься значення 1.

## Випадки застосування відфільтрованих індексів

- Стовпці містять добре визначені підмножини даних, вказані в інструкціях SELECT. <u>Наприклад</u>:
  - розріджені стовпці, які містять невелику кількість неNULL значень;
  - різнорідні стовпці, які містять категорії даних;
  - стовпці, які містять діапазони значень, такі як сума грошей, відрізки часу і дати;
  - секції таблиці, які визначені логікою простого порівняння для значень стовпців.

## Правило 1 використання відфільтрованих індексів

- □ Зниження затрат на обслуговування відфільтрованого індексу є більш наглядним, коли кількість рядків в індексі є невеликою у порівнянні з повнотабличним індексом.
  - Якщо відфільтрований індекс включає велику кількість рядків, його обслуговування буде більш затратним у порівнянні з повнотабличним, і його використання є недоцільним.

## Правило 2 використання відфільтрованих індексів

- Відфільтровані індекси визначаються на одній таблиці і підтримують лише прості оператори порівняння.
  - Якщо виникає необхідність у критерії фільтру, який посилається на кілька таблиць або має складну логіку, то треба створювати віртуальну таблицю.

## Рекомендації щодо написання запитів на вибірку даних

- □ Іншим способом оптимізації виконання запитів, крім використання індексів, є написання коректних запитів на вибірку з
  - оптимізацією умов
  - оптимізацією сортування
  - оптимізацією групування і агрегування
  - оптимізацією з'єднання таблиць

### Оптимізація умов

- □ Пошук даних за умовою (фраза WHERE) використовується найчастіше
- □ Оптимізуючи умови, можна досягнути значної продуктивності запитів
- Чим простіші (коротші) операнди використовуються в операціях порівняння, тим вища швидкість виконання запиту

### Оптимізація умов. Оператори порівняння

впорядковані за швидкістю виконання, починаючи з найшвидшого:

- □ >, >=, <, <=
- LIKE
- □ <>

- □ Якщо в умові пошуку використовуються декілька кон'юнкцій AND, то при відсутності відповідних індексів і статистики такі вирази будуть виконуватись зліва направо, причому ніякі круглі дужки не зможуть змінити такий порядок.
- □ Принцип перевірки послідовності кон'юнкцій такий, що якщо перший вираз є хибним, то решта перевірятись не будуть.
- □ Тому доцільно першими розміщати вирази, імовірність істинності яких є малою.
- Якщо для пари виразів імовірність приблизно однакова, то першим треба розмістити найпростіший.
- Зауважимо, що такі рекомендації не відносяться до СУБД Oracle, де умови починають перевірятись з кінця. Відповідно, порядок виразів повинен бути протилежним.

- □ Ситуація з оператором ОК є протилежною до кон'юнкції.
- □ Вирази в умові повинні бути розміщеними у порядку спадання імовірностей – від найбільшої.
- Фірма Microsoft рекомендує використовувати цей метод при побудові запитів.
- Це не відноситься до СУБД Oracle, де умови з диз'юнкцією повинні розміщуватись за зростанням імовірності істиності.

- □ При використанні в умовах пошуку поєднання AND і OR можна використати розподілений закон:
  - A AND (B OR C) = (A AND B) OR (A AND C)
- Дослідним шляхом встановлено, що вираз зліва виконується швидше.
- Деякі СУБД самі вміють оптимізувати запити такого типу. Але краще відразу записати оптимальний вираз.

- □ Операцію NOT завжди потрібно приводити до читабельного вигляду.
  - Наприклад, умову WHERE NOT (column1>5) відразу можна записати: WHERE column1<=5.</p>
- Складніші умови можна записати, використовуючи правило де Моргана:

NOT(A AND B) = (NOT A) OR (NOT B);NOT(A OR B) = (NOT A) AND (NOT B).

■ Наприклад, умову
 WHERE NOT (column1>5 OR column2=7)
 можна перетворити на простішу:
 WHERE column1<=5 AND column2<>7.

#### Оптимізація умов

- □ Предикат IN працює набагато швидше від серій диз'юнкцій OR.
  - Тому необхідно завжди заміняти OR на IN, де це можливо, не зважаючи на те, що деякі СУБД самі роблять таку оптимізацію.
- □ Якщо ж є вибір використання *IN* чи *BETWEEN*, то ефективніше використовувати BETWEEN.
  - Наприклад, умова
    WHERE column1 IN (1,3,4,5)
    оптимізується до вигляду:
    WHERE column1 BETWEEN 1 AND 5
    AND column1

#### Оптимізація умов

□ Якщо в умові пошуку часто використовується пошук за шаблоном з використанням *оператора LIKE* і через це виникають проблеми з швидкістю виконання запитів, то необхідно розглянути можливість використання служби повнотектового пошуку MicrosoftSearch, яка базується на full-text індексах і працює набагато швидше.

## Оптимізація умов і використання індексів

- Основний спосіб підвищення швидкодії фрази WHEREзастосувати індекси для організації пошуку.
- □ Однак, це ще не гарантує, що вони будуть використані, оскільки не всі логічні предикати операцій порівняння допускають використання індексів.
- □ Індекси, як правило не застосовуються для виконання операцій пошуку з такими предикатами: IS NULL, <>, NOT, NOT EXIST, NOT IN, NOT LIKE.
- □ Не може використовувати індекс оператор LIKE, який починається з символу підстановки (маски).
  - Наприклад, умова пошуку column LIKE `П%′ має потенційну можливість використати індекс, а умова column LIKE `%П′
    - такої можливості не має.
  - Хоча можна примусити сервер застосувати індекс і в цьому випадку через підказку оптимізатору.

#### Оптимізація сортування

- □ Чим більший об'єм даних, тим більше часу займе сортування.
- □ На швидкість сортування впливає три фактора:
  - кількість вибраних рядів;
  - кількість стовпців, вказаних у фразі ORDER BY;
  - довжина і тип стовпців, вказаних у фразі ORDER BY.
- Альтернативою такій оптимізації є використання індексів.

#### Оптимізація групування

- Необхідно використовувати якомога менше стовпців групування.
- □ І якщо у фразі HAVING не використовується агрегатна функція, то вважається, що вона є еквівалентною до фрази WHERE, яку і потрібно використовувати для оптимізації запиту.
- □ Однак, необхідно враховувати специфіку СУБД, оскільки в багатьох СУБД фрази WHERE і НАVING не є рівноцінними і виконуються не однаково.
- □ Якщо відбувається групування без агрегатних функцій, доцільно використовувати оператор DISTINCT.

## Оптимізація групування і агрегування

- □ При використанні агрегатних функцій MIN і MAX необхідно враховувати, що виконуються вони швидше, якщо записані окремо.
  - Це означає, що їх краще використовувати в різних запитах або в запитах з використання операції об'єднання UNION.
- □ При використанні функції SUM:
  - оптимальнішим буде вираз SUM(x+y), а не SUM(x)+SUM(y).
  - для віднімання навпаки: SUM(x)-SUM(y) обробляється швидше, ніж SUM(x-y).

#### Оптимізація з'єднання таблиць

- □ Операція з'єднання таблиць (JOIN) є найдорожчою операцією реляційної алгебри, не враховуючи операції декартового добутку.
- Швидкість виконання таких операцій залежить від організації самої таблиці, використання первинного та зовнішніх ключів.
- □ Однозначних рекомендацій як використовувати різні способи з'єднання таблиць не існує. Все залежить від конкретного випадку і архітектури бази даних.

#### Оптимізація з'єднання таблиць

- □ Якщо необхідно регулярно виконувати операції з'єднання таблиць, то ефективність в загальному випадку буде оптимальною при з'єднанні стовпців однакового типу, кожен з яких має власний індекс. При цьому вважається, що
  - кластерні індекси кращі некластерних,
  - чим вища селективність стовпців, за якими виконується з'єднання, тим краще.
- □ На швидкість з'єднання впливає тип даних полів зв'язку. Вважається, що найшвидше виконується з'єднання для полів з цілочисельними типами даних.

#### Оптимізація з'єднання таблиць

- □ Якщо запит вимагає з'єднання більше чотирьох таблиць, необхідно подумати про денормалізацію бази даних або про створення індексованої віртуальної таблиці, яка реалізує попередні з'єднання.
- □ Необхідно уникати використання \* для вибору усіх стовпців в обох таблицях.
- Ефективність з'єднання буде кращою, якщо фізичні сторінки даних заповнені максимально щільно. Це можна досягнути за допомогою:
  - задання високого значення параметру FILLFACTOR для індексних сторінок,
  - шляхом оптимізації типів даних і розмірів стовпців у таблицях.
- □ Необхідно вчасно перебудовувати індекси.

### Типи операторів з'єднання в SQL Server при виконанні запитів

- NESTED LOOP JOIN з'єднання блоками з використанням вкладених циклів (використовуючи або не використовуючи індекси);
- $\square$  MERGE JOIN з'єднання сортуванням-злиттям;
- □ HASH JOIN з'єднання через використання функції перемішування (хеш-функції).

Однозначних рекомендацій як використовувати різні способи з'єднання таблиць не існує. Все залежить від конкретного випадку і архітектури бази даних. Ознайомитись з алгоритмами цих способів з'єднання можна у відповідній літературі.

#### Оптимізація підзапитів

- □ Використання підзапитів є близькою альтернативою до операції з'єднання таблиць.
- □ Основна проблема для їх оптимізації не оптимізація самого коду, а вибір правильного способу для реалізації запиту.
- □ Існують рекомендації, коли доцільніше використовувати підзапити, а коли з'єднання таблиць.
- Основною перевагою використання оператора JOIN полягає в тому, що не потрібно вказувати СУБД яким способом виконувати з'єднання таблиць.
- □ Основна перевага підзапитів така, що цикл підзапиту може мати декілька ітерацій, що й може покращити продуктивність виконання запиту.

## Переваги з'єднання таблиць по відношенню до підзапитів

- якщо запит містить фразу WHERE, то оптимізатор при використанні з'єднання оцінює запит в цілому, а у випадку підзапитів, вони будуть оптимізовані окремо (по частинах);
- □ деякі СУБД (наприклад, Oracle) ефективніше працюють з операціями з'єднання таблиць;
- після з'єднання в результатній таблиці виводиться вся вказана інформація, а в підзапитах частина даних використовується як параметр в умові пошуку.

### Переваги підзапитів по відношенню до з'єднання таблиць

- підзапити допускають використання більш вільних, різноманітних умов
- □ підзапити можуть містити фрази GROUP BY, HAVING, які набагато складніше оптимізувати в операціях з'єднання таблиць

### Дякую за увагу

Опрацювати: Д.Петковіч «Microsoft SQL Server 2012. Руководство для начинающих» *ст.294-300*